

## Entrega 1 – Catherine Johana Rincón Maya

### Contexto de aplicación

A nivel mundial existe una presión por la reducción de la contaminación ambiental, las emisiones de carbono y la dependencia de los combustibles fósiles, por esto, se deben implementar estrategias y políticas que permitan garantizar la seguridad energética y lograr el desarrollo sostenible de la sociedad (Ge et al., 2021; Zhang et al., 2022). Los estudios muestran que la industria de la energía y el transporte son los principales factores que contribuyen a esta problemática, lo cual proporciona una fuerza impulsadora significativa para el desarrollo de nuevas fuentes de energía renovable y sistemas de transporte limpios (Zhang et al., 2022).

En el sector del transporte, el uso de los vehículos eléctricos ha venido en aumento como estrategia para reducir las emisiones, mejorar la calidad del aire, conservar la energía y proteger el medio ambiente (Ge et al., 2021; Zhang et al., 2022). Los vehículos eléctricos tienen diferentes componentes, cuya falla impide su correcto funcionamiento, y en consecuencia, se genera una falla directa en el vehículo. Uno de los componentes más críticos en el vehículo es la batería, ésta es el principal suministro de energía y componente de almacenamiento que puede costar hasta un 30% del costo total del vehículo. Por esto, una batería de larga duración es fundamental para lograr la viabilidad económica de los vehículos eléctricos, la implementación de energía renovable y el desarrollo de la infraestructura de redes inteligentes (Ge et al., 2021; Hu et al., 2020).

Las baterías de iones de litio (LIB, por sus siglas en inglés: *Lithium-ion battery*), se consideran la fuente de energía más viable para este tipo de vehículos, debido a su buena eficiencia, ciclo de vida prolongado, alta potencia y densidades de energía (Ge et al., 2021; Hu, et al., 2020; Zhang et al., 2022). Sin embargo, uno de los problemas de estos componentes críticos es la degradación durante el funcionamiento, ya que comúnmente es un proceso complejo, que incluye muchas reacciones físico químicas y variación de parámetros en el tiempo que presentan un comportamiento no lineal (Hu et al., 2020). Para evitar fallas potencialmente peligrosas y riesgos de seguridad tales como incendios, fugas y explosiones, entre otros, es esencial monitorear la variación de los parámetros que intervienen en la degradación de la batería.

Para comprender el rendimiento de la batería, es importante tener información de variables como corriente, voltaje, temperatura, capacidad y determinar el estado de salud (SOH, por sus siglas en inglés: *State of Health*) a partir de la capacidad de la batería. Para esto, se define que la capacidad inicial de la batería es del 100% y se va disminuyendo ciclo a ciclo (Ge et al., 2021; Zhang et al., 2022).

$$SOH = \frac{\text{Capacidad actual}}{\text{Capacidad al inicio de la vida}} * 100\%$$

Con estos datos, se puede predecir de manera precisa la vida útil restante (RUL, por sus siglas en inglés: *Remaining Useful Life*) de la batería en condiciones de funcionamiento, lo que permite garantizar la seguridad y confiabilidad del vehículo (Ge et al., 2021; Hu et al., 2020).

## Objetivo de machine learning

El objetivo de machine learning es predecir la vida útil remanente (RUL) en número de ciclos o tiempo que le resta a la batería a partir de la información recolectada de variables como: ciclo, temperatura ambiente, fecha (fecha y hora de inicio del ciclo), voltaje de la batería, corriente de la batería, temperatura de la batería, corriente de carga, voltaje de carga, tiempo (tiempo del ciclo en segundos), capacidad de la batería y estado de salud (SOH).

## Dataset: tipo de datos, tamaño (número de datos y tamaño en disco), distribución de las clases

Para realizar la predicción del RUL, se tomarán los datos públicos de la NASA: Battery Data Set 1 (Saha et al., 2007), el cual está compuesto por 4 datasets de baterías enumeradas así: batería 5, 6, 7 y 18. Cada uno de los datasets de la batería está compuesto por 10 variables que se presentan en la Tabla 1, se adiciona manualmente una variable calculada llamada SOH a partir del dato de la capacidad, que permitirá hacer una predicción más precisa del RUL.

**Tabla 1.** Tipo de datos de cada variable

| Tipo de dato            | Variable   |
|-------------------------|--|
| Entera - Int            | Ciclo - Temperatura ambiente   |
| Fecha y hora - Datetime | Fecha  |
| Flotante - Float        | Voltaje - corriente - temperatura - corriente de carga - voltaje de carga - tiempo - capacidad de la batería - SOH |

En la Tabla 2, se presentan la cantidad de datos para cada uno de los datasets de las baterías. Estos datasets tienen un tamaño en disco de 42,5 GB.

**Tabla 2.** Cantidad de datos de cada dataset de las baterías

| Dataset    | Cantidad de datos (filas) |
|------------|---------------------------|
| Batería 5  | 50.285                    |
| Batería 6  | 50.285                    |
| Batería 7  | 50.285                    |
| Batería 18 | 34.866                    |

Además, la variable respuesta, RUL, sigue una distribución Weibull.

### **Métricas de desempeño (de machine learning y negocio)**

Como métricas de desempeño de machine learning se puede hacer uso de: el error cuadrático medio (RMSE), el error porcentual medio absoluto (MAPE) y el error absoluto medio (MAE).

Además, con una buena predicción del RUL, se pueden reducir los costos de mantenimiento, prevenir accidentes y reducir las fallas que presentan los vehículos, garantizando la seguridad y confiabilidad del vehículo (Ge et al., 2021; Hu et al., 2020).

### **Referencias y resultados previos**

Park et al. (2020) desarrollaron un modelo de predicción implementando redes LSTM y usando los datos públicos de la NASA, en el cual se obtuvo un 0.47% – 6.45% de MAPE.

### **Referencias**

- Ge, M. F., Liu, Y., Jiang, X., & Liu, J. (2021). A review on state of health estimations and remaining useful life prognostics of lithium-ion batteries. *Measurement*, 174, 109057. <https://doi.org/10.1016/J.MEASUREMENT.2021.109057>
- Hu, X., Xu, L., Lin, X., & Pecht, M. (2020). Battery Lifetime Prognostics. *Joule*, 4(2), 310–346. <https://doi.org/10.1016/J.JOULE.2019.11.018>
- Park, K., Choi, Y., Choi, W., Ryu, H., & Kim, H. (2020). LSTM-Based Battery Remaining Useful Life Prediction With Multi-Channel Charging Profiles. *Computer Science*, 8, 20786-20798. 10.1109/ACCESS.2020.2968939
- Saha, B. & Goebel, K. (2007). Battery Data Set. NASA Ames Prognostics Data Repository (<http://ti.arc.nasa.gov/project/prognostic-data-repository>), NASA Ames Research Center, Moffett Field, CA
- Zhang, X., Li, Z., Luo, L., Fan, Y., & Du, Z. (2022). A review on thermal management of lithium-ion batteries for electric vehicles. *Energy*, 238, 121652. <https://doi.org/10.1016/J.ENERGY.2021.121652>